Planteamiento del problema y objetivos

Proyecto: Detección de patrones en la monitorización de sistemas distribuidos

Versión: Ciclo 4 - Reorientación del método, ampliación del corpus y objetivos

Alcance: Sistemas distribuidos observados mediante métricas, registros y trazas, con validación en sistemas controlados desplegados localmente.

Nota de alcance

El planteamiento se sustenta en los veintidós estudios disponibles en la carpeta *papers*. El corpus aporta un contexto internacional y técnico, pero no contiene estadísticas específicas de Colombia. La contribución central prevista es un método interpretable de reconocimiento de patrones sobre una representación conjunta de métricas, registros y trazas. El método se integrará mediante una extensión para Grafana; esta plataforma puede reunir consultas y visualizaciones de diversas fuentes, pero no unifica por sí sola las señales para el análisis.

1. Planteamiento del problema

Los servicios digitales dependen de sistemas distribuidos que deben operar continuamente. Sin embargo, su escala, sus dependencias y su lógica interna dificultan detectar y diagnosticar fallos, que pueden ocasionar interrupciones, pérdida de rendimiento y afectaciones económicas y reputacionales [1]. Para comprender su comportamiento, la observabilidad emplea métricas, que cuantifican el estado y el desempeño; registros o *logs*, que documentan eventos y cambios; y trazas, que reconstruyen el recorrido de las solicitudes entre servicios [1]. Aunque AIOps busca procesar estos datos mediante aprendizaje automático [1], [2], persiste una brecha entre su generación masiva y una interpretación oportuna, confiable y comprensible.

Los indicios de degradación se encuentran inmersos en una mayoría de eventos normales, por lo que la inspección manual no escala y las reglas predefinidas solo reconocen situaciones conocidas [3]. Un patrón anómalo puede manifestarse en atributos, frecuencias, intervalos, parámetros, correlaciones o contextos temporales. Además, los eventos concurrentes pueden llegar intercalados y sin identificadores consistentes, lo cual dificulta reconstruir sus relaciones [3].

La dificultad no se resuelve únicamente mostrando las señales en una misma herramienta. Métricas, registros y trazas difieren en estructura, granularidad, volumen y semántica, de modo que su análisis conjunto exige definir adquisición, sincronización, contexto compartido, transformación y representación. Los modelos gráficos son una alternativa documentada [4]–[8], pero no constituyen un requisito del proyecto. Kaiju demuestra otra posibilidad: representar las tres señales como eventos y aplicar operaciones de filtrado, unión y correlación sobre flujos, conservando procesamientos específicos por modalidad [11]. Una propuesta *schema-first* advierte que vincular señales exige metadatos semánticos compatibles [16]. Otros estudios relacionan trazas y registros mediante identificadores compartidos [17] o

fusionan las tres modalidades para detectar y diagnosticar anomalías [18], [19]; sus arquitecturas son antecedentes, no requisitos. Por ello, el flujo y la representación conjunta son decisiones de investigación, no funciones delegables por completo en la plataforma de visualización.

La interpretabilidad también requiere una definición verificable. Una explicación puede no corresponder al criterio con el que el detector marcó una anomalía; por ello, la literatura recomienda evaluar su fidelidad, alcance y utilidad para el destinatario [12]. Asimismo, se distingue entre generar atribuciones —tarea algorítmica— e interpretarlas con conocimiento experto para reconocer una condición y decidir una acción —tarea cognitiva— [13]. En este proyecto, reconocer patrones deberá producir evidencia comprensible que apoye, sin reemplazar, el juicio del operador.

Los resultados publicados proceden de conjuntos y escenarios limitados, por lo que el desempeño y la utilidad operativa deben validarse. AIOpsLab permite desplegar sistemas, generar carga, inyectar fallos, exportar telemetría y evaluar agentes en condiciones reproducibles [9]; las revisiones recopilan tareas, datos y métricas disponibles [10]. ITBench confirma la pertinencia de separar el diagnóstico, la localización y el tiempo requerido por agentes que consultan señales de observabilidad [14]. Profesionales del sector reportan saturación de alertas, correlación difícil, metadatos insuficientes y dependencia del conocimiento experto [15], [20]. RCAEval y LO2 aportan casos reproducibles y datos etiquetados, aunque evidencian límites de cobertura y alineación [21], [22].

Si estas limitaciones persisten, cabe esperar una monitorización fragmentada y reactiva, con falsas alarmas, omisiones y verificación manual. Un método opaco o una interfaz que solo agregue paneles podría aumentar la carga cognitiva en vez de mejorar las decisiones. Se requiere, por tanto, investigar una representación multimodal y un método interpretable, integrarlos en una herramienta de observabilidad y comprobar su aporte en sistemas controlados.

Pregunta problema

¿Cómo se puede mejorar la toma de decisiones en la monitorización de sistemas distribuidos mediante un método interpretable de reconocimiento de patrones en datos multimodales?

2. Objetivos

2.1 Objetivo general

Diseñar un método interpretable de reconocimiento de patrones a partir de datos multimodales que apoye la toma de decisiones en la monitorización de sistemas distribuidos.

2.2 Objetivos específicos

1. Diseñar un flujo de datos de observabilidad para sistemas distribuidos que integre métricas, registros y trazas en una representación conjunta apta para el análisis.
2. Explorar un método interpretable de aprendizaje automático para reconocer patrones en la representación conjunta de los datos de observabilidad de sistemas distribuidos.
3. Diseñar una extensión para una herramienta de observabilidad que integre el método de aprendizaje automático y presente los patrones identificados como información de apoyo a la toma de decisiones.

4. Validar la extensión diseñada mediante pruebas reproducibles con agentes de evaluación sobre sistemas controlados desplegados localmente, valorando el desempeño del método y la utilidad de los resultados para la toma de decisiones.

Referencias

[1] L. Zhang et al., "A survey of AIOps in the era of large language models," arXiv preprint arXiv:2507.12472, Jul. 2025, doi: 10.48550/arXiv.2507.12472.

[2] J. Diaz-de-Arcaya, A. I. Torre-Bastida, G. Zárate, R. Miñón, and A. Almeida, "A joint study of the challenges, opportunities, and roadmap of MLOps and AIOps: A systematic survey," ACM Comput. Surv., vol. 56, no. 4, Art. no. 84, pp. 1–30, Oct. 2023, doi: 10.1145/3625289.

[3] M. Landauer, S. Onder, F. Skopik, and M. Wurzenberger, "Deep learning for anomaly detection in log data: A survey," Mach. Learn. Appl., vol. 12, Art. no. 100470, Jun. 2023, doi: 10.1016/j.mlwa.2023.100470.

[4] Á. Brandón, M. Solé, A. Huélamo, D. Solans, M. S. Pérez, and V. Muntés-Mulero, "Graph-based root cause analysis for service-oriented and microservice architectures," J. Syst. Softw., vol. 159, Art. no. 110432, Jan. 2020, doi: 10.1016/j.jss.2019.110432.

[5] C. Lee, T. Yang, Z. Chen, Y. Su, and M. R. Lyu, "Eadro: An end-to-end troubleshooting framework for microservices on multi-source data," in Proc. 45th IEEE/ACM Int. Conf. Softw. Eng. (ICSE), 2023, pp. 1750–1762, doi: 10.1109/ICSE48619.2023.00150.

[6] S. Zhang et al., "Robust failure diagnosis of microservice system through multimodal data," IEEE Trans. Serv. Comput., vol. 16, no. 6, pp. 3851–3864, Nov.–Dec. 2023, doi: 10.1109/TSC.2023.3290018.

[7] C. Zhao et al., "Robust multimodal failure detection for microservice systems," in Proc. 29th ACM SIGKDD Conf. Knowl. Discov. Data Min. (KDD), 2023, pp. 5639–5649, doi: 10.1145/3580305.3599902.

[8] G. Yu, P. Chen, Y. Li, H. Chen, X. Li, and Z. Zheng, "Nezha: Interpretable fine-grained root causes analysis for microservices on multi-modal observability data," in Proc. 31st ACM Joint Eur. Softw. Eng. Conf. Symp. Found. Softw. Eng. (ESEC/FSE), 2023, pp. 553–565, doi: 10.1145/3611643.3616249.

[9] Y. Chen et al., "AIOpsLab: A holistic framework to evaluate AI agents for enabling autonomous clouds," Proc. Mach. Learn. Syst., vol. 7, 2025. [Online]. Available: https://proceedings.mlsys.org/paper_files/paper/2025/hash/d1f9e4a9f109b6e8b75ed362736f22ec-Abstract-Conference.html

[10] S. Zhang et al., "Failure diagnosis in microservice systems: A comprehensive survey and analysis," ACM Trans. Softw. Eng. Methodol., vol. 35, no. 1, Art. no. 2, pp. 1–55, Dec. 2025, doi: 10.1145/3715005.

[11] M. Scrocca, R. Tommasini, A. Margara, E. Della Valle, and S. Sakr, "The Kaiju project: Enabling event-driven observability," in Proc. 14th ACM Int. Conf. Distributed Event-Based Syst. (DEBS), 2020, pp. 85–96, doi: 10.1145/3401025.3401740.

[12] Z. Li, Y. Zhu, and M. van Leeuwen, "A survey on explainable anomaly detection," ACM Trans. Knowl. Discov. Data, vol. 18, no. 1, Art. no. 23, pp. 1–54, Jan. 2024, doi: 10.1145/3609333.

[13] J. Sipple and A. Youssef, "A general-purpose method for applying explainable AI for anomaly detection," in Foundations of Intelligent Systems, Lecture Notes in Computer Science, vol. 13515, 2022, pp. 162–174, doi: 10.1007/978-3-031-16564-1_16.

[14] S. Jha et al., “ITBench: Evaluating AI agents across diverse real-world IT automation tasks,” in Proc. 42nd Int. Conf. Mach. Learn. (ICML), Proc. Mach. Learn. Res., vol. 267, pp. 27134–27197, 2025. [Online]. Available: https://proceedings.mlr.press/v267/jha25a.html

[15] S. Niedermaier, F. Koetter, A. Freymann, and S. Wagner, “On observability and monitoring of distributed systems: An industry interview study,” in Service-Oriented Computing, Lecture Notes in Computer Science, vol. 11895, 2019, pp. 36–52, doi: 10.1007/978-3-030-33702-5_3.

[16] Y. Shkuro, B. Renard, and A. Singh, “Positional paper: Schema-first application telemetry,” arXiv preprint arXiv:2206.11380, Jun. 2022, doi: 10.48550/arXiv.2206.11380.

[17] C. Zhang, X. Peng, C. Sha, K. Zhang, Z. Fu, X. Wu, Q. Lin, and D. Zhang, “DeepTraLog: Trace-log combined microservice anomaly detection through graph-based deep learning,” in Proc. 44th Int. Conf. Softw. Eng. (ICSE), 2022, pp. 623–634, doi: 10.1145/3510003.3510180.

[18] J. Huang, Y. Yang, H. Yu, J. Li, and X. Zheng, “Twin graph-based anomaly detection via attentive multi-modal learning for microservice system,” in Proc. 38th IEEE/ACM Int. Conf. Automated Softw. Eng. (ASE), 2023, pp. 66–78, doi: 10.1109/ASE56229.2023.00138.

[19] C. Hou, T. Jia, Y. Wu, Y. Li, and J. Han, “Diagnosing performance issues in microservices with heterogeneous data source,” in Proc. IEEE Int. Conf. Parallel Distrib. Process. Appl., Big Data Cloud Comput., Sustain. Comput. Commun., Social Comput. Netw. (ISPA/BDCloud/SocialCom/SustainCom), 2021, pp. 493–500, doi: 10.1109/ISPA-BDCloud-SocialCom-SustainCom52081.2021.00074.

[20] M. Steidl, B. Dornauer, M. Felderer, R. Ramler, M.-C. Racasan, and M. Gattringer, “How industry tackles anomalies during runtime: Approaches and key monitoring parameters,” in Proc. 50th Euromicro Conf. Softw. Eng. Adv. Appl. (SEAA), 2024, pp. 364–372, doi: 10.1109/SEAA64295.2024.00062.

[21] L. Pham, H. Zhang, H. Ha, F. Salim, and X. Zhang, “RCAEval: A benchmark for root cause analysis of microservice systems with telemetry data,” in Companion Proc. ACM Web Conf. (WWW Companion), 2025, pp. 777–780, doi: 10.1145/3701716.3715290.

[22] A. Bakhtin, J. Nyyssölä, Y. Wang, N. Ahmad, K. Ping, M. Esposito, M. Mäntylä, and D. Taibi, “LO2: Microservice API anomaly dataset of logs and metrics,” in Proc. 21st Int. Conf. Predictive Models Data Analytics Softw. Eng. (PROMISE), 2025, pp. 1–10, doi: 10.1145/3727582.3728682.