Propuesta de investigación

Proyecto: Reconocimiento interpretable de patrones en la monitorización de sistemas distribuidos

Versión: Ciclo 6 en desarrollo

Estado: Borrador para la presentación de la propuesta

Nota de alcance

El documento se sustenta en veinticuatro fuentes: veintidós antecedentes sobre observabilidad, análisis multimodal, interpretabilidad y evaluación, y dos referencias metodológicas incorporadas en este ciclo. El contexto disponible es internacional y técnico; no se presentan cifras específicas de Colombia. La propuesta se limita a un prototipo experimental validado en sistemas controlados desplegados localmente.

1 Planteamiento del problema

Los servicios digitales dependen de sistemas distribuidos cuyos componentes cooperan a través de redes, procesos y capas de infraestructura. La escala, la concurrencia y las dependencias entre servicios dificultan observar el estado global y localizar las condiciones asociadas con una degradación [1], [10]. Para examinar ese comportamiento se emplean métricas, que cuantifican recursos y desempeño; registros, que documentan acontecimientos; y trazas, que reconstruyen el recorrido de las solicitudes. Cada señal describe una parte distinta del sistema y ninguna ofrece por sí sola una visión suficiente.

El volumen de telemetría supera la capacidad de inspección manual, mientras las reglas y firmas predefinidas dependen de situaciones anticipadas [3], [20]. Los patrones de interés pueden expresarse como cambios de frecuencia, combinaciones de parámetros, secuencias, relaciones temporales o variaciones contextuales. Su reconocimiento se dificulta por el ruido, el desbalance, la falta de etiquetas, la pérdida de datos y la intercalación de eventos procedentes de procesos concurrentes [3].

El análisis conjunto tampoco se obtiene al reunir las fuentes en una misma vista. Métricas, registros y trazas difieren en formato, granularidad, frecuencia, volumen y significado. Relacionarlas exige definir cómo se adquieren, identifican, sincronizan, transforman y fusionan, además de tratar ausencias y desfases temporales [11], [16]–[19], [22]. La literatura reporta resultados favorables de métodos multimodales, pero las evaluaciones se concentran en pocos sistemas y emplean tareas, fallos y métricas distintas [5]–[8], [18], [19]. Por ello, sus resultados muestran viabilidad, no una solución generalizable a cualquier sistema distribuido.

Los profesionales también reportan saturación de datos y alertas, dificultades para correlacionar señales por falta de metadatos, vistas poco navegables y dependencia del conocimiento experto [15], [20]. Esto justifica la necesidad de una herramienta experimental que conecte la preparación multimodal, el reconocimiento de patrones y la presentación de evidencia dentro del flujo de monitorización. Su función no sería acumular paneles ni decidir por el operador, sino reducir la fragmentación de la información,

conservar el vínculo entre cada resultado y sus datos de origen, y facilitar el examen de posibles relaciones relevantes para una decisión.

Esa herramienta requiere un método interpretable. Una explicación comprensible puede no ser fiel al criterio que produjo un resultado; por ello, la interpretabilidad debe evaluarse mediante correspondencia con los datos y acontecimientos relevantes, fidelidad, comprensibilidad y utilidad para la tarea [12], [13]. También deben distinguirse el reconocimiento de un patrón, la clasificación de una condición, la localización de un componente y la identificación de una posible causa, pues son capacidades diferentes y una correlación no demuestra causalidad [10], [14].

Si estas limitaciones persisten, cabe esperar que la monitorización continúe apoyándose en revisiones fragmentadas y que la verificación manual siga concentrando tiempo y conocimiento especializado. La investigación debe establecer si un método interpretable aplicado a las tres señales puede producir resultados trazables y útiles bajo condiciones controladas, sin anticipar una mejora ni generalizar más allá de los escenarios evaluados.

Pregunta de investigación

¿De qué manera un método interpretable de reconocimiento de patrones en métricas, registros y trazas puede apoyar la toma de decisiones en la monitorización de sistemas distribuidos?

2 Objetivos

2 1 Objetivo general

Desarrollar y validar un método interpretable de reconocimiento de patrones a partir del análisis conjunto de métricas, registros y trazas, integrado en un prototipo que apoye la toma de decisiones en la monitorización de sistemas distribuidos.

2 2 Objetivos específicos

1. Diseñar un flujo de datos de observabilidad que adquiera, identifique, sincronice, transforme y fusione métricas, registros y trazas en una representación conjunta apta para el análisis.
2. Desarrollar un método interpretable de aprendizaje automático para reconocer patrones en la representación conjunta e integrarlo en un prototipo que presente los resultados y su evidencia asociada.
3. Validar el prototipo mediante pruebas reproducibles con agentes de evaluación sobre sistemas controlados desplegados localmente, valorando la integración multimodal, el desempeño, la interpretabilidad y la utilidad de los resultados para tareas de decisión definidas.

3 Alcances y limitaciones

El proyecto llegará hasta un prototipo funcional experimental compuesto por un flujo de datos multimodal, un método interpretable de aprendizaje automático, un componente de procesamiento y una extensión para Grafana. El flujo abarcará adquisición, identificadores compartidos, sincronización temporal, transformaciones por modalidad, fusión y tratamiento de datos faltantes. El prototipo presentará los patrones y la evidencia asociada sin atribuir a Grafana la recolección, el almacenamiento, la unificación semántica o la ejecución del método.

La investigación estudiará conjuntamente métricas, registros y trazas. La técnica de aprendizaje automático, las variables de entrada y la representación final se seleccionarán durante el desarrollo; no se presupone aprendizaje profundo, grafos, Transformers, modelos de lenguaje ni otra arquitectura. Las capacidades de detección, clasificación, priorización o localización solo se incorporarán si la definición de patrón y los resultados experimentales las sustentan.

La validación se restringirá a sistemas controlados desplegados localmente, configuraciones reproducibles, condiciones conocidas y ventanas temporales documentadas. Los resultados no se generalizarán a todos los sistemas distribuidos. No se incluye despliegue industrial, operación continua, alta disponibilidad, remediación automática, certificación de seguridad ni demostración definitiva de causalidad. Los agentes de evaluación ejecutarán tareas previamente definidas; no constituyen una población humana ni sustituyen un estudio de usabilidad, aceptación o impacto organizacional con operadores.

4 Justificación

La monitorización de sistemas distribuidos produce señales complementarias, pero su volumen y heterogeneidad dificultan relacionarlas durante el análisis. Los estudios con profesionales reportan saturación de información, correlación limitada por metadatos insuficientes y dependencia del conocimiento experto [15], [20]. A su vez, la evidencia técnica muestra que la integración multimodal requiere semántica, identificadores, sincronización y transformaciones explícitas [11], [16]–[19]. Estas condiciones sustentan la necesidad de investigar un artefacto que conecte la preparación de datos, el reconocimiento de patrones y la presentación de evidencia trazable.

La contribución científica será un método interpretable de aprendizaje automático aplicado a una representación conjunta de métricas, registros y trazas. La investigación no fijará de antemano una familia de modelos; comparará alternativas según la definición de patrón, los datos disponibles, el desempeño y los criterios de interpretabilidad. Esta decisión evita confundir una salida visual o una explicación posterior con evidencia fiel y útil [12], [13].

La contribución tecnológica será un prototipo experimental que integre el método en una extensión para Grafana, manteniendo separadas las responsabilidades de las fuentes, el flujo de datos, el componente de procesamiento y la interfaz. Su valor práctico se examinará mediante tareas de decisión delimitadas, no mediante la promesa de automatizar el diagnóstico. La validación reproducible en sistemas locales permitirá contrastar integración, desempeño, interpretabilidad y utilidad con datos de referencia explícitos [9], [14], [21]. El resultado aportará un método, un flujo y evidencia experimental documentada, con límites claros para orientar trabajos posteriores y evitar generalizaciones no sustentadas.

5 Marco teórico

5 1 Observabilidad de sistemas distribuidos

La monitorización comprueba condiciones conocidas mediante indicadores, umbrales y alertas. La observabilidad amplía ese propósito al permitir inferir el estado interno de un sistema a partir de las señales que produce [1], [15]. En sistemas distribuidos, esta inferencia es incompleta porque los componentes cambian, operan de forma concurrente y exponen datos con distinto nivel de detalle. La

observabilidad no equivale a disponer de más paneles: requiere relacionar la evidencia con el contexto operacional y con la tarea que motiva el análisis.

El análisis asistido por aprendizaje automático busca organizar grandes volúmenes de telemetría y apoyar tareas operativas [1], [2]. Sin embargo, los resultados dependen de la calidad de las señales y de las decisiones de preparación. El proyecto adopta la observabilidad como base para examinar patrones, no como garantía de conocimiento completo sobre el sistema.

5 2 Dependencias y propagación

Una solicitud puede atravesar varios servicios, instancias y recursos. Por esta razón, una degradación observada en un punto puede aparecer asociada con cambios posteriores en otros componentes. La arquitectura y las relaciones temporales ofrecen contexto para reconstruir esa propagación [4], [10], pero no prueban por sí solas una causa.

Los grafos de dependencias son una alternativa documentada para modelar componentes e interacciones [4]–[8]. También pueden emplearse representaciones tabulares, temporales, orientadas a eventos o híbridas. La elección debe corresponder a los datos, la definición de patrón y la capacidad de rastrear cada resultado; una estructura topológica no será un requisito previo.

5 3 Señales multimodales

Las métricas resumen cantidades como utilización, latencia o tasa de errores. Los registros describen acontecimientos mediante mensajes estructurados o semiestructurados. Las trazas representan operaciones enlazadas a lo largo del recorrido de una solicitud. Estas señales ofrecen perspectivas complementarias sobre tendencias, eventos e interacciones [1].

Diversos estudios integran las tres modalidades para detectar, clasificar o localizar condiciones de interés [5]–[8], [18], [19]. Sus resultados respaldan la viabilidad del análisis conjunto, aunque no son directamente comparables porque cambian los sistemas, las etiquetas, los tipos de fallo y las métricas. En esta propuesta las tres señales forman el núcleo del método y ninguna se considera una ampliación opcional.

5 4 Representación conjunta

Una representación conjunta exige más que consultar varias fuentes. El flujo debe establecer identificadores compartidos, correspondencia semántica, unidades, ventanas de correlación, transformaciones y criterios para datos ausentes [11], [16]. También debe conservar la proveniencia para reconstruir qué observaciones participaron en un patrón.

La literatura presenta estrategias basadas en eventos, identificadores de traza, dependencias temporales y mecanismos de fusión [11], [17]–[19]. Un conjunto de datos real muestra, además, que la ausencia de trazas completas limita el análisis trimodal aunque existan registros y métricas a gran escala [22]. Por tanto, la representación será una decisión experimental documentada y evaluada por su cobertura, consistencia y utilidad para el método.

5 5 Aprendizaje automático y reconocimiento de patrones

Las reglas y los umbrales son comprensibles, cuentan con soporte operativo y siguen siendo frecuentes [20]. Su cobertura depende, sin embargo, de condiciones y relaciones previstas. El aprendizaje automático

permite inferir regularidades supervisadas o no supervisadas a partir de los datos, pero ninguna técnica es adecuada para todos los escenarios [3], [5]–[8], [17]–[19].

Un patrón puede ser una frecuencia, una secuencia, una combinación de valores, una relación temporal o un comportamiento contextual. La investigación deberá operacionalizar qué patrón busca, qué unidad analiza y qué salida produce antes de seleccionar el modelo. Se compararán alternativas acordes con los datos y los recursos, sin asumir que una arquitectura más compleja tendrá mejor desempeño o interpretabilidad.

5 6 Calidad y cambio de los datos

La telemetría puede contener ruido, duplicados, pérdidas, formatos variables, relojes desalineados y eventos intercalados [3], [16], [22]. La escasez de etiquetas y el desbalance dificultan la evaluación porque los casos de interés suelen ser menos frecuentes y su clasificación exige conocimiento del dominio. Estas condiciones pueden generar asociaciones espurias o esconder relaciones pertinentes.

Las versiones, configuraciones, cargas e infraestructuras cambian con el tiempo, lo que puede reducir la vigencia de una representación o de un modelo [1]–[3]. El proyecto no promete adaptación continua. Registrará versiones, condiciones de captura y transformaciones para limitar cada conclusión a las ventanas y escenarios evaluados.

5 7 Interpretabilidad y evidencia

Una puntuación o visualización no basta para considerar interpretable un método. La literatura distingue la anomalía esperada por el usuario, el criterio del detector y la explicación generada; una explicación comprensible puede ser infiel al modelo [12]. También separa la atribución producida por un algoritmo de la interpretación que realiza una persona al relacionarla con una condición y una decisión [13].

La propuesta evaluará la evidencia mediante fidelidad, correspondencia con variables o acontecimientos relevantes, comprensibilidad y utilidad para la tarea. Cuando existan referencias adecuadas podrá medirse el error de atribución [13]. La evidencia describirá asociaciones y contribuciones observadas, sin convertirlas automáticamente en afirmaciones causales.

5 8 Apoyo a la toma de decisiones

Detectar una desviación, clasificarla, localizar un componente y proponer una posible causa son tareas distintas [5]–[8], [10]. El apoyo a la decisión consiste en presentar información pertinente y trazable para una tarea definida, no en sustituir el juicio del operador. La priorización o localización solo será válida en la granularidad respaldada por los datos de referencia.

Los estudios industriales reportan saturación de alertas y dependencia del conocimiento experto [15], [20]. Los marcos de evaluación operativa separan tarea, resultado y tiempo [14]. En el proyecto, la utilidad se examinará con agentes de evaluación que ejecuten tareas reproducibles; este procedimiento no permitirá inferir aceptación humana ni impacto organizacional.

5 9 Integración del prototipo

La arquitectura del prototipo separará cuatro responsabilidades. Las fuentes producirán o almacenarán la telemetría; el flujo preparará y relacionará las señales; el componente de procesamiento ejecutará el

método; y la extensión presentará los patrones con su contexto y evidencia. Esta separación evita atribuir a la interfaz una integración semántica que depende de decisiones previas [11], [16].

Grafana será la plataforma de la extensión, no el método ni el repositorio de datos. La interfaz conservará vínculos hacia las observaciones de origen y expondrá únicamente capacidades respaldadas por la evaluación. No realizará remediación automática ni ocultará las incertidumbres y limitaciones del resultado.

5 10 Validación reproducible

La validación de un artefacto multimodal requiere documentar el sistema, la carga, la instrumentación, las condiciones introducidas, las ventanas temporales y las transformaciones [9], [14], [21]. Los bancos existentes aportan escenarios, casos y líneas base, pero no sustituyen la definición de las variables específicas del proyecto.

Los datos de referencia para la evaluación, denominados también oráculo de evaluación en experimentación de software, son el conjunto explícito de etiquetas, condiciones conocidas, componentes intervenidos, secuencias esperadas o criterios de aceptación contra el que se comparan los resultados. No son un agente ni una herramienta. Los agentes ejecutan tareas; los datos de referencia permiten juzgar sus respuestas y las salidas del prototipo. La validación distinguirá integración multimodal, desempeño, interpretabilidad y utilidad, y limitará las conclusiones a los escenarios observados.

6 Metodología propuesta

6 1 Selección metodológica

La investigación seguirá Design Science Research Methodology o DSRM. Esta metodología es adecuada porque el resultado previsto es un artefacto compuesto por un flujo multimodal, un método interpretable, un componente de procesamiento y una extensión de interfaz. DSRM organiza la investigación en seis actividades que parten de un problema relevante, conducen al diseño de un artefacto y exigen demostrarlo y evaluarlo frente a objetivos explícitos [23].

CRISP-ML(Q) estructura el desarrollo y aseguramiento de calidad de aplicaciones de aprendizaje automático [24], mientras MLOps aborda capacidades de ingeniería y operación a lo largo del ciclo de vida [2]. No se adoptan como metodologías adicionales porque el proyecto debe abarcar el artefacto completo y no llegará a una operación industrial continua. Sus prácticas técnicas podrán consultarse durante el desarrollo del modelo sin alterar la elección de DSRM como única metodología general.

6 2 Aplicación de DSRM

4. **Identificación y motivación del problema.** Se consolidará la evidencia sobre fragmentación de señales, dificultades de correlación, límites de los métodos existentes y necesidad de resultados interpretables. La salida será el problema delimitado, la pregunta de investigación y el conjunto inicial de requisitos.
5. **Definición de los objetivos de la solución.** Se operacionalizarán patrón, integración multimodal, desempeño, interpretabilidad, apoyo a la decisión, utilidad y agente de evaluación. Para cada variable se fijarán criterios observables, métricas candidatas, restricciones y datos de referencia.

6. **Diseño y desarrollo.** Se diseñará el flujo de adquisición, identificación, sincronización, transformación y fusión. Después se compararán técnicas de aprendizaje automático compatibles con los datos y los criterios de interpretabilidad. El método seleccionado se implementará en un componente de procesamiento y se integrará con la extensión para Grafana. Esta actividad será iterativa y conservará la trazabilidad entre requisitos, decisiones, datos, versiones y resultados.
7. **Demostración.** El prototipo se ejecutará sobre uno o más sistemas controlados desplegados localmente. Se prepararán cargas, configuraciones y condiciones de interés reproducibles, y se verificará que el flujo produce la representación conjunta y que la interfaz presenta los patrones con su evidencia.
8. **Evaluación.** Los resultados observados se compararán con los objetivos y los datos de referencia. La integración se valorará mediante cobertura, consistencia semántica, alineación temporal y tratamiento de ausencias. El desempeño empleará métricas acordes con la tarea finalmente definida. La interpretabilidad examinará fidelidad, correspondencia y comprensibilidad. La utilidad se medirá mediante el cumplimiento, la exactitud y el tiempo de tareas ejecutadas por agentes, sin tratar estas pruebas como un estudio con operadores humanos. Los resultados podrán motivar iteraciones hacia el diseño o la definición de objetivos [23].
9. **Comunicación.** Se documentarán el artefacto, las decisiones de diseño, el protocolo experimental, los resultados, las limitaciones y los materiales necesarios para reproducir las pruebas. La comunicación incluirá la propuesta, el informe de resultados y una demostración del prototipo.

6 3 Unidades y datos de evaluación

Las unidades de análisis serán los componentes del sistema distribuido y las observaciones multimodales asociadas con ventanas temporales definidas. Los agentes de evaluación serán ejecutores de tareas instrumentadas, no sujetos humanos. Los datos de referencia especificarán para cada escenario qué condición se introdujo, dónde y cuándo ocurrió, qué observaciones se esperan y qué respuestas se consideran aceptables. Se emplearán conjuntos separados para ajustar, seleccionar y evaluar el método cuando la técnica escogida lo requiera. Todas las ejecuciones registrarán versiones del sistema, configuración, carga, semillas, transformaciones y versión del modelo.

7 Plan de trabajo

El plan sigue las actividades de DSRM y mantiene una secuencia de dependencias. Las iteraciones podrán devolver el trabajo a una etapa anterior cuando la demostración o la evaluación evidencien que un requisito no se cumple.

Etapa	Actividades principales	Resultado esperado
1 Delimitación	Actualizar el corpus, consolidar requisitos, reformular la pregunta y precisar patrón, interpretabilidad, utilidad y agente de evaluación	Problema, pregunta, objetivos y criterios de éxito aprobados
2 Diseño experimental	Seleccionar el sistema local, definir cargas y condiciones de interés, establecer instrumentación, ventanas y datos de referencia	Protocolo experimental reproducible
3 Flujo multimodal	Definir fuentes, esquemas, identificadores, sincronización, transformaciones, fusión, manejo de ausencias y proveniencia	Flujo implementado y conjunto multimodal versionado
4 Exploración	Preparar líneas base, seleccionar variables, comparar técnicas de	Método seleccionado con justificación

Etapa	Actividades principales	Resultado esperado
del método	aprendizaje y evaluar alternativas de interpretabilidad	experimental
5 Desarrollo del prototipo	Implementar el componente de procesamiento, contratos de consulta, trazabilidad y extensión para Grafana	Prototipo funcional integrado
6 Demostración	Ejecutar escenarios controlados, verificar el flujo completo y registrar resultados y fallos de integración	Evidencia de funcionamiento de extremo a extremo
7 Validación	Ejecutar pruebas con agentes, comparar con los datos de referencia y valorar integración, desempeño, interpretabilidad y utilidad	Resultados, análisis de errores y límites de validez
8 Comunicación	Consolidar documentación, materiales de reproducción, informe final y presentación del prototipo	Entregables académicos y técnicos del proyecto

Referencias

[1] L. Zhang et al., "A survey of AIOps in the era of large language models," arXiv preprint arXiv:2507.12472, Jul. 2025, doi: 10.48550/arXiv.2507.12472.

[2] J. Diaz-de-Arcaya, A. I. Torre-Bastida, G. Zárate, R. Miñón, and A. Almeida, "A joint study of the challenges, opportunities, and roadmap of MLOps and AIOps: A systematic survey," ACM Comput. Surv., vol. 56, no. 4, Art. no. 84, pp. 1–30, Oct. 2023, doi: 10.1145/3625289.

[3] M. Landauer, S. Onder, F. Skopik, and M. Wurzenberger, "Deep learning for anomaly detection in log data: A survey," Mach. Learn. Appl., vol. 12, Art. no. 100470, Jun. 2023, doi: 10.1016/j.mlwa.2023.100470.

[4] Á. Brandón, M. Solé, A. Huélamo, D. Solans, M. S. Pérez, and V. Muntés-Mulero, "Graph-based root cause analysis for service-oriented and microservice architectures," J. Syst. Softw., vol. 159, Art. no. 110432, Jan. 2020, doi: 10.1016/j.jss.2019.110432.

[5] C. Lee, T. Yang, Z. Chen, Y. Su, and M. R. Lyu, "Eadro: An end-to-end troubleshooting framework for microservices on multi-source data," in Proc. 45th IEEE/ACM Int. Conf. Softw. Eng. (ICSE), 2023, pp. 1750–1762, doi: 10.1109/ICSE48619.2023.00150.

[6] S. Zhang et al., "Robust failure diagnosis of microservice system through multimodal data," IEEE Trans. Serv. Comput., vol. 16, no. 6, pp. 3851–3864, Nov.–Dec. 2023, doi: 10.1109/TSC.2023.3290018.

[7] C. Zhao et al., "Robust multimodal failure detection for microservice systems," in Proc. 29th ACM SIGKDD Conf. Knowl. Discov. Data Min. (KDD), 2023, pp. 5639–5649, doi: 10.1145/3580305.3599902.

[8] G. Yu, P. Chen, Y. Li, H. Chen, X. Li, and Z. Zheng, "Nezha: Interpretable fine-grained root causes analysis for microservices on multi-modal observability data," in Proc. 31st ACM Joint Eur. Softw. Eng. Conf. Symp. Found. Softw. Eng. (ESEC/FSE), 2023, pp. 553–565, doi: 10.1145/3611643.3616249.

[9] Y. Chen et al., "AIOpsLab: A holistic framework to evaluate AI agents for enabling autonomous clouds," Proc. Mach. Learn. Syst., vol. 7, 2025. [Online]. Available: https://proceedings.mlsys.org/paper_files/paper/2025/hash/d1f9e4a9f109b6e8b75ed362736f22ec-Abstract-Conference.html

[10] S. Zhang et al., "Failure diagnosis in microservice systems: A comprehensive survey and analysis," ACM Trans. Softw. Eng. Methodol., vol. 35, no. 1, Art. no. 2, pp. 1–55, Dec. 2025, doi: 10.1145/3715005.

[11] M. Scrocca, R. Tommasini, A. Margara, E. Della Valle, and S. Sakr, "The Kaiju project: Enabling event-driven observability," in Proc. 14th ACM Int. Conf. Distributed Event-Based Syst. (DEBS), 2020, pp. 85–96, doi: 10.1145/3401025.3401740.

[12] Z. Li, Y. Zhu, and M. van Leeuwen, "A survey on explainable anomaly detection," ACM Trans. Knowl. Discov. Data, vol. 18, no. 1, Art. no. 23, pp. 1–54, Jan. 2024, doi: 10.1145/3609333.

[13] J. Sipple and A. Youssef, "A general-purpose method for applying explainable AI for anomaly detection," in Foundations of Intelligent Systems, Lecture Notes in Computer Science, vol. 13515, 2022, pp. 162–174, doi: 10.1007/978-3-031-16564-1_16.

[14] S. Jha et al., "ITBench: Evaluating AI agents across diverse real-world IT automation tasks," in Proc. 42nd Int. Conf. Mach. Learn. (ICML), Proc. Mach. Learn. Res., vol. 267, pp. 27134–27197, 2025. [Online]. Available: https://proceedings.mlr.press/v267/jha25a.html

[15] S. Niedermaier, F. Koetter, A. Freymann, and S. Wagner, "On observability and monitoring of distributed systems: An industry interview study," in Service-Oriented Computing, Lecture Notes in Computer Science, vol. 11895, 2019, pp. 36–52, doi: 10.1007/978-3-030-33702-5_3.

[16] Y. Shkuro, B. Renard, and A. Singh, “Positional paper: Schema-first application telemetry,” arXiv preprint arXiv:2206.11380, Jun. 2022, doi: 10.48550/arXiv.2206.11380.

[17] C. Zhang, X. Peng, C. Sha, K. Zhang, Z. Fu, X. Wu, Q. Lin, and D. Zhang, “DeepTraLog: Trace-log combined microservice anomaly detection through graph-based deep learning,” in Proc. 44th Int. Conf. Softw. Eng. (ICSE), 2022, pp. 623–634, doi: 10.1145/3510003.3510180.

[18] J. Huang, Y. Yang, H. Yu, J. Li, and X. Zheng, “Twin graph-based anomaly detection via attentive multi-modal learning for microservice system,” in Proc. 38th IEEE/ACM Int. Conf. Automated Softw. Eng. (ASE), 2023, pp. 66–78, doi: 10.1109/ASE56229.2023.00138.

[19] C. Hou, T. Jia, Y. Wu, Y. Li, and J. Han, “Diagnosing performance issues in microservices with heterogeneous data source,” in Proc. IEEE Int. Conf. Parallel Distrib. Process. Appl., Big Data Cloud Comput., Sustain. Comput. Commun., Social Comput. Netw. (ISPA/BDCloud/SocialCom/SustainCom), 2021, pp. 493–500, doi: 10.1109/ISPA-BDCloud-SocialCom-SustainCom52081.2021.00074.

[20] M. Steidl, B. Dornauer, M. Felderer, R. Ramler, M.-C. Racasan, and M. Gattringer, “How industry tackles anomalies during runtime: Approaches and key monitoring parameters,” in Proc. 50th Euromicro Conf. Softw. Eng. Adv. Appl. (SEAA), 2024, pp. 364–372, doi: 10.1109/SEAA64295.2024.00062.

[21] L. Pham, H. Zhang, H. Ha, F. Salim, and X. Zhang, “RCAEval: A benchmark for root cause analysis of microservice systems with telemetry data,” in Companion Proc. ACM Web Conf. (WWW Companion), 2025, pp. 777–780, doi: 10.1145/3701716.3715290.

[22] A. Bakhtin, J. Nyyssölä, Y. Wang, N. Ahmad, K. Ping, M. Esposito, M. Mäntylä, and D. Taibi, “LO2: Microservice API anomaly dataset of logs and metrics,” in Proc. 21st Int. Conf. Predictive Models Data Analytics Softw. Eng. (PROMISE), 2025, pp. 1–10, doi: 10.1145/3727582.3728682.

[23] K. Peffers, T. Tuunanen, M. A. Rothenberger, and S. Chatterjee, “A design science research methodology for information systems research,” J. Manage. Inf. Syst., vol. 24, no. 3, pp. 45–77, 2007, doi: 10.2753/MIS0742-1222240302.

[24] S. Studer, T. B. Bui, C. Drescher, A. Hanuschkin, L. Winkler, S. Peters, and K.-R. Müller, “Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology,” Mach. Learn. Knowl. Extr., vol. 3, no. 2, pp. 392–413, Apr. 2021, doi: 10.3390/make3020020.