Planteamiento del problema y objetivos

Proyecto: Detección de patrones en la monitorización de sistemas distribuidos

Versión: Ciclo 3 - Síntesis del planteamiento, pregunta problema y objetivos

Alcance: Sistemas distribuidos desplegados en entornos contenerizados administrados con Kubernetes.

Nota de alcance

El planteamiento se sustenta en los diez estudios disponibles en la carpeta papers. El corpus aporta un contexto internacional y técnico, pero no contiene estadísticas específicas de Colombia. El producto previsto es un plugin para Grafana basado en aprendizaje automático e integración de métricas, logs y trazas mediante un grafo dinámico; el caso de estudio concreto todavía debe seleccionarse.

1. Planteamiento del problema

Los servicios digitales dependen de sistemas distribuidos que deben operar continuamente. Sin embargo, su escala, sus dependencias y su lógica interna dificultan detectar, localizar y diagnosticar fallos, que pueden ocasionar interrupciones, pérdida de rendimiento y afectaciones económicas y reputacionales [1]. Para comprender su comportamiento, la observabilidad reúne métricas, que cuantifican el estado y el desempeño; registros o logs, que documentan eventos y cambios; y trazas, que reconstruyen el recorrido de las solicitudes entre servicios [1]. Aunque AIOps busca procesar estos datos mediante aprendizaje automático [1], [2], persiste una brecha entre su generación masiva y una interpretación oportuna, confiable y comprensible.

En este contexto, los indicios de degradación se encuentran inmersos en una mayoría de eventos normales, por lo que la inspección manual no escala y las reglas predefinidas solo reconocen situaciones conocidas [3]. Un patrón anómalo puede manifestarse en atributos, frecuencias, intervalos, parámetros, correlaciones o contextos temporales. Además, los eventos concurrentes pueden llegar intercalados y sin identificadores consistentes, lo cual dificulta reconstruir sus relaciones [3].

La infraestructura tampoco es uniforme: sus componentes, dependencias y topología pueden cambiar durante la operación. Una representación gráfica multiatributo permite modelar componentes, conexiones, señales y propagación de fallos [4]. Eadro integra detección y localización sobre un grafo derivado de trazas y muestra que las tres señales aportan información complementaria [5]. Otros estudios multimodales construyen grafos de dependencias para localizar componentes y determinar tipos de fallo [6], o modelan relaciones heterogéneas para detectar fallos de instancia [7]. Los grafos de eventos también permiten producir explicaciones más granulares [8]. Estos antecedentes respaldan estudiar un grafo dinámico, pero no justifican asumir de antemano una arquitectura específica.

Los principales síntomas son la sobrecarga de datos con pérdida de contexto, la cobertura parcial de anomalías, el envejecimiento de modelos estáticos y las alertas difíciles de explicar y convertir en

acciones [1], [3]. Las causas incluyen logs no estructurados, métricas de alta dimensionalidad, trazas complejas, datos faltantes o mal etiquetados, desbalance y cambios del software que modifican la línea base [2], [3]. Los resultados publicados proceden de conjuntos limitados y su generalización entre topologías requiere validación. Marcos experimentales reproducibles permiten desplegar microservicios, generar carga, inyectar fallos y recoger telemetría en Kubernetes [9], y una revisión reciente identifica conjuntos de datos, herramientas y métricas para evaluar detección, clasificación y localización [10].

Si estas limitaciones persisten, cabe esperar una monitorización fragmentada y reactiva, con falsas alarmas, fallos no detectados, verificación manual y menor confianza operativa. También podrían prolongarse los incidentes, aumentar sus efectos en cascada y permanecer invisibles patrones basados en parámetros, temporalidad, correlaciones o trazas [1], [3]. Una automatización con modelos aislados, costosos, poco adaptables o poco explicables podría añadir complejidad en lugar de reducirla, limitando la resiliencia y la capacidad de contener fallos [1], [2], [10].

Pregunta problema

¿Cómo se puede mejorar la toma de decisiones en la monitorización de sistemas distribuidos mediante un método interpretable de reconocimiento de patrones en datos multimodales?

2. Objetivos

2.1 Objetivo general

Diseñar un plugin para Grafana basado en aprendizaje automático que integre métricas, registros y trazas mediante un grafo dinámico de sistemas distribuidos.

2.2 Objetivos específicos

1. Construir una representación dinámica de la infraestructura y de su estado operativo que modele como grafo los servicios o instancias, sus interacciones derivadas de las trazas y los atributos extraídos de las métricas y los registros, preservando su correspondencia temporal y topológica.
2. Diseñar un método de aprendizaje automático que analice la información integrada en el grafo para detectar la existencia de fallos, identificar su tipo y estimar la prioridad de los componentes posiblemente causantes.
3. Implementar el método en un plugin para Grafana que permita obtener las señales de observabilidad, ejecutar el análisis y presentar el fallo detectado, su tipo y la lista priorizada de componentes posiblemente causantes.
4. Validar el plugin en entornos Kubernetes con fallos de causa conocida y diferentes topologías, evaluando la detección de fallos, la identificación de su tipo, la precisión al localizar la causa raíz y la estabilidad de los resultados ante cambios topológicos.

Referencias

[1] L. Zhang et al., “A survey of AIOps in the era of large language models,” arXiv preprint arXiv:2507.12472, Jul. 2025, doi: 10.48550/arXiv.2507.12472.

[2] J. Diaz-de-Arcaya, A. I. Torre-Bastida, G. Zárate, R. Miñón, and A. Almeida, “A joint study of the challenges, opportunities, and roadmap of MLOps and AIOps: A systematic survey,” ACM Comput. Surv., vol. 56, no. 4, Art. no. 84, pp. 1–30, Oct. 2023, doi: 10.1145/3625289.

[3] M. Landauer, S. Onder, F. Skopik, and M. Wurzenberger, “Deep learning for anomaly detection in log data: A survey,” Mach. Learn. Appl., vol. 12, Art. no. 100470, Jun. 2023, doi: 10.1016/j.mlwa.2023.100470.

[4] Á. Brandón, M. Solé, A. Huélamo, D. Solans, M. S. Pérez, and V. Muntés-Mulero, “Graph-based root cause analysis for service-oriented and microservice architectures,” J. Syst. Softw., vol. 159, Art. no. 110432, Jan. 2020, doi: 10.1016/j.jss.2019.110432.

[5] C. Lee, T. Yang, Z. Chen, Y. Su, and M. R. Lyu, “Eadro: An end-to-end troubleshooting framework for microservices on multi-source data,” in Proc. 45th IEEE/ACM Int. Conf. Softw. Eng. (ICSE), 2023, pp. 1750–1762, doi: 10.1109/ICSE48619.2023.00150.

[6] S. Zhang et al., “Robust failure diagnosis of microservice system through multimodal data,” IEEE Trans. Serv. Comput., vol. 16, no. 6, pp. 3851–3864, Nov.–Dec. 2023, doi: 10.1109/TSC.2023.3290018.

[7] C. Zhao et al., “Robust multimodal failure detection for microservice systems,” in Proc. 29th ACM SIGKDD Conf. Knowl. Discov. Data Min. (KDD), 2023, pp. 5639–5649, doi: 10.1145/3580305.3599902.

[8] G. Yu, P. Chen, Y. Li, H. Chen, X. Li, and Z. Zheng, “Nezha: Interpretable fine-grained root causes analysis for microservices on multi-modal observability data,” in Proc. 31st ACM Joint Eur. Softw. Eng. Conf. Symp. Found. Softw. Eng. (ESEC/FSE), 2023, pp. 553–565, doi: 10.1145/3611643.3616249.

[9] Y. Chen et al., “AIOpsLab: A holistic framework to evaluate AI agents for enabling autonomous clouds,” Proc. Mach. Learn. Syst., vol. 7, 2025. [Online]. Available: https://proceedings.mlsys.org/paper_files/paper/2025/hash/d1f9e4a9f109b6e8b75ed362736f22ec-Abstract-Conference.html

[10] S. Zhang et al., “Failure diagnosis in microservice systems: A comprehensive survey and analysis,” ACM Trans. Softw. Eng. Methodol., vol. 35, no. 1, Art. no. 2, pp. 1–55, Dec. 2025, doi: 10.1145/3715005.